ScientistTwo
以自主 AI 拓展人类知识边界

Jaehyun Nam[1] · Jinsung Yoon[1] · Yanzhou Pan[1] · Yubo Wang[2] · Rui Meng[1] · Parthasarathy Ranganathan[1] · Tomas Pfister[1]

[1] Google Cloud AI Research [2] University of Waterloo

输入科学问题，运行完整研究周期

给定科学问题，ScientistTwo 自主识别基线方法的局限，提出新想法、执行实验，并生成论文与可执行代码。

让实验与评审反馈驱动研究

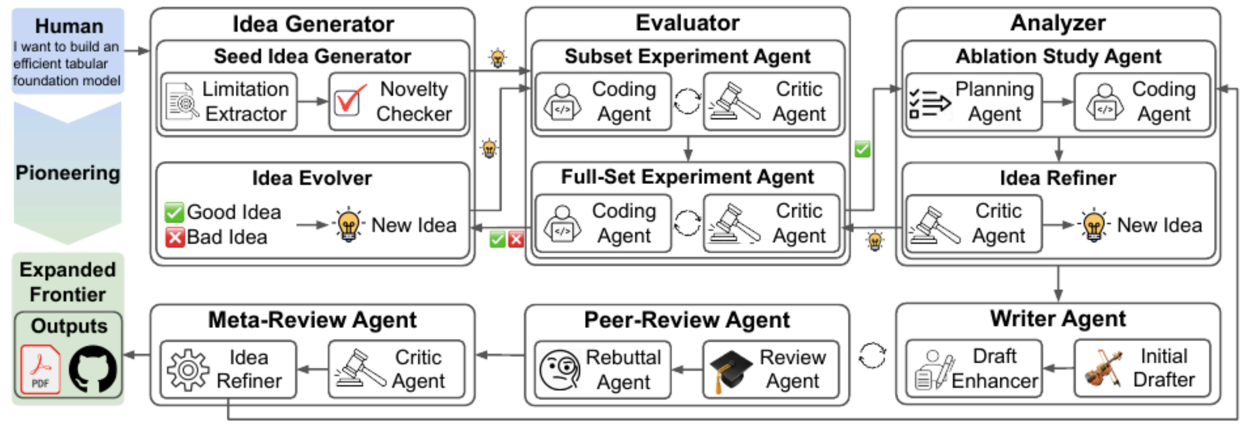
Human
I want to build an efficient tabular foundation model
Pioneering
Expanded Frontier
Outputs
PDF
Idea Generator
Seed Idea Generator
Limitation Extractor
Novelty Checker
Idea Evolver
Good Idea
Bad Idea
New Idea
Evaluator
Subset Experiment Agent
Coding Agent
Critic Agent
Full-Set Experiment Agent
Coding Agent
Critic Agent
Analyzer
Ablation Study Agent
Planning Agent
Coding Agent
Idea Refiner
Critic Agent
New Idea
Meta-Review Agent
Idea Refiner
Critic Agent
Peer-Review Agent
Rebuttal Agent
Review Agent
Writer Agent
Draft Enhancer
Initial Drafter

原图 3 · ScientistTwo 将想法生成、子集到全量评估、消融分析、写作、模拟同行评审和元评审连接为闭环。

闭环如何推进

阶段	决策与反馈
Evaluation · 评估	先在子集筛选，再将有潜力的想法扩展至全量基准。
Ablation · 消融	分离组件贡献，修正方法后重新验证。
Rebuttal · 答辩	围绕评审质疑补做实验，并将结果写回论文。

有进展，也有明确的评估边界

80.4%

ScientistTwo 在 107 个目标问题中改进了 86 个。

25.2%

ScientistTwo 成功案例相对人类基线的平均性能增益。

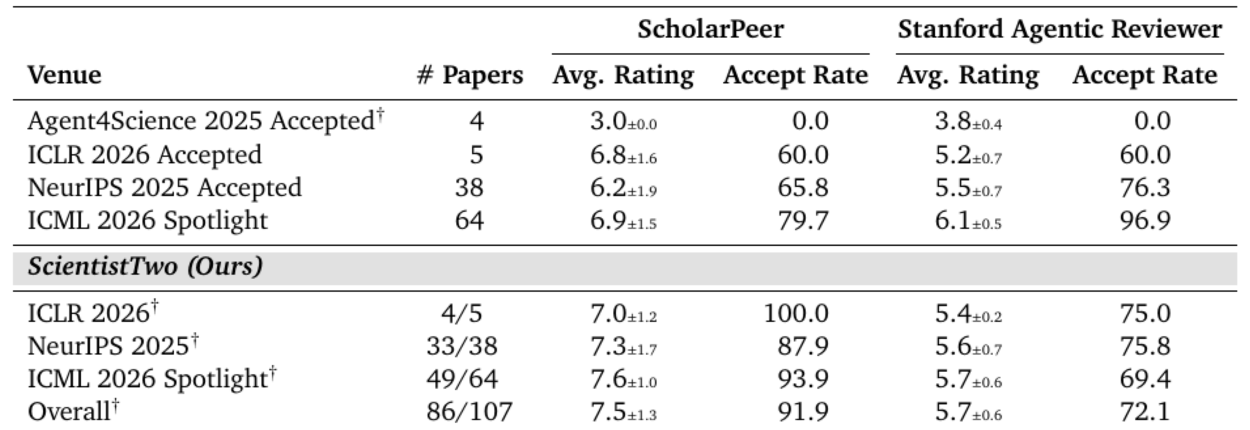

Venue	# Papers	ScholarPeer Avg. Rating	ScholarPeer Accept Rate	Stanford Agentic Reviewer Avg. Rating	Stanford Agentic Reviewer Accept Rate
Agent4Science 2025 Accepted†	4	$3.0_{\pm 0.0}$	0.0	$3.8_{\pm 0.4}$	0.0
ICLR 2026 Accepted	5	$6.8_{\pm 1.6}$	60.0	$5.2_{\pm 0.7}$	60.0
NeurIPS 2025 Accepted	38	$6.2_{\pm 1.9}$	65.8	$5.5_{\pm 0.7}$	76.3
ICML 2026 Spotlight	64	$6.9_{\pm 1.5}$	79.7	$6.1_{\pm 0.5}$	96.9
ScientistTwo (Ours)					
ICLR 2026†	4/5	$7.0_{\pm 1.2}$	100.0	$5.4_{\pm 0.2}$	75.0
NeurIPS 2025†	33/38	$7.3_{\pm 1.7}$	87.9	$5.6_{\pm 0.7}$	75.8
ICML 2026 Spotlight†	49/64	$7.6_{\pm 1.0}$	93.9	$5.7_{\pm 0.6}$	69.4
Overall†	86/107	$7.5_{\pm 1.3}$	91.9	$5.7_{\pm 0.6}$	72.1

原表 3 · AI 评审器对人类参考论文与 ScientistTwo 生成论文评分。评分范围为 1–10；录用列为模拟录用率（%）。† 表示 AI 生成论文。

两种 AI 评审器，承担不同角色

在成功生成的 86 篇论文中，ScientistTwo 在 ScholarPeer 下的模拟录用率为 91.9%，在 Stanford Agentic Reviewer 下为 72.1%。前者也用于指导改稿；后者在开发阶段保留作独立评估。这些指标不等同于真实会议录用。

> Table 4 中，ScientistTwo 成功案例的增益中位数为 7.7，均值为 25.2（单位均为 %）。均值不能代表每项任务的典型提升。

迭代为什么有效

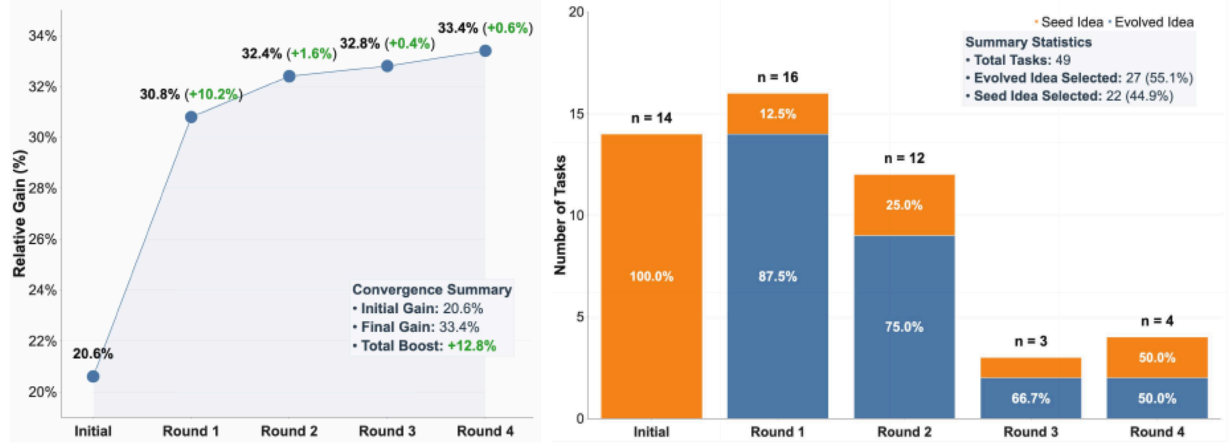

(a) Idea Improvement (b) Distribution of Selected Best Ideas

原图 9 · 在 ICML 来源任务上，ScientistTwo 的提升集中于早期迭代。后续入选想法主要来自演化，成功和失败的执行轨迹都会成为反馈。

另有人工评估交叉验证

9 位资深评审者评估了 33 篇 NeurIPS 来源论文。ScientistTwo 的整体相对偏好评分为 3.0，达到与人类论文持平的标尺；方法严谨性仍略逊。

自主实证研究的潜力与局限

ScientistTwo 展示了自主实证研究能力，但尚不能稳定产出 spotlight 级概念突破。在 33 个 NeurIPS 来源任务的成本分析中，单次研究平均约需 2.5 天、花费 3,765 美元，包含模型 token 与虚拟机成本。

来源：Nam 等 · ScientistTwo · arXiv:2609.19644v1 · 保留原始图表；说明文字可编辑。